Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

Más-menos ajustado al hipergrafo

Nathaniel Josephs[1] y Elizabeth Upton[2]

1. Universidad Estatal de Carolina del Norte, Departamento de Estadística
2. Williams College, Departamento de Matemáticas y Estadística

arXiv:2403.20214v3 [stat.ME] 8 de mayo de 2025

Resumen

En los deportes de equipo, las estadísticas de clasificación tradicionales no permiten evaluar simultáneamente tanto a los jugadores individuales como a las combinaciones de jugadores. Las métricas para la clasificación de jugadores individuales a menudo no incluyen los efectos de interacción entre grupos de jugadores, mientras que los métodos para evaluar alineaciones completas no pueden utilizarse para identificar el valor de combinaciones de jugadores de orden inferior (parejas, tríos, etc.). Dado que las clasificaciones de los jugadores y de las alineaciones dependen intrínsecamente unas de otras, estas limitaciones pueden afectar la precisión de las evaluaciones de desempeño. Para abordar esto, proponemos un enfoque novedoso de «plus-minus ajustado» (APM) que permite clasificar simultáneamente a los jugadores individuales, las combinaciones de jugadores de orden inferior y las alineaciones completas dentro de un equipo. El método se ajusta a la estructura de dependencia completa y se basa en la conexión entre el APM y la representación hipergráfica de un equipo. Analizamos las similitudes de nuestro enfoque con otras métricas avanzadas, lo demostramos utilizando datos de la NBA de 2012 a 2022 y sugerimos posibles líneas de trabajo para el futuro.

Palabras clave: Redes, alineación generalizada, regresión, NBA, grafo de líneas, laplaciano de grafos

1 Introducción

Las clasificaciones de jugadores individuales son fundamentales en el mundo del deporte: a los aficionados les encanta debatir si sus jugadores favoritos son los mejores en la actualidad o en la historia; esos mismos jugadores tienen un incentivo para rendir debido a las negociaciones de contratos y a los premios de fin de temporada, como el de Jugador Más Valioso; y la dirección de los equipos se dedica a armar una plantilla ganadora. Las clasificaciones de los jugadores sirven de base para una competencia sana, la toma de decisiones estratégicas y la participación de los aficionados, lo que subraya la importancia de su precisión para todos los involucrados. En los deportes individuales, las clasificaciones se pueden obtener fácilmente a través de pruebas cronometradas y resultados de enfrentamientos directos. Sin embargo, en los deportes de equipo, separar los efectos individuales de factores endógenos —como la sinergia del equipo y el rival— y de factores exógenos —como el entrenamiento y la ventaja de jugar en casa— puede ser un ejercicio complejo.

Uno de los enfoques más comunes para medir el efecto *de un individuo* en los deportes de equipo es el «plus-minus» (PM) sin ajustar. Utilizado originalmente en el hockey, el PM de un jugador es la diferencia acumulada en el marcador de su equipo cuando ese jugador está en el partido. Aunque intuitivamente atractivo, el PM es sensible a los patrones de sustitución. Por ejemplo, un jugador muy bueno puede inflar artificialmente el PM de sus compañeros de equipo, y cuantificar este efecto se vuelve complicado cuando ciertas combinaciones de jugadores comparten constantemente

tiempo de juego. El enfoque más común para tener esto en cuenta se conoce como «más-menos ajustado» (APM). El APM se desarrolló para el baloncesto (Rosenbaum 2004) y el hockey (Macdonald 2011) como un método para comparar a jugadores individuales sin dejar de considerar a aquellos que juegan juntos. También se ha extendido, mediante un marco bayesiano, al fútbol y al fútbol americano (Matano et al. 2023, Sabin 2021). En la sección 3 proporcionamos algunos detalles matemáticos del APM.

La intención del APM y sus variantes es aislar el efecto de un jugador individual (Hvattum 2019). Sin embargo, este enfoque no logra captar los efectos *de interacción* entre los jugadores. La experiencia, las habilidades complementarias y la sinergia general a menudo dan lugar a un grupo de jugadores cuyo efecto combinado supera la suma de sus contribuciones individuales. Este fenómeno explica, en parte, por qué los patrones de sustitución no son uniformemente aleatorios y por qué los directivos y entrenadores desempeñan un papel crucial en el éxito de un equipo. Del mismo modo, al evaluar y clasificar la contribución de un individuo al éxito de un equipo, es fundamental tomar en cuenta la capacidad del jugador para crear sinergias con las diversas combinaciones de sus compañeros de equipo. Nos referimos a estas diversas combinaciones (individuos, parejas, tríos, etc.) como *alineaciones generalizadas* y proponemos un enfoque novedoso para cuantificar simultáneamente la contribución de todas las alineaciones generalizadas de un equipo.

Para evaluar las alineaciones generalizadas utilizando el APM, existen dos opciones posibles:

1. Sumar el APM de todos los jugadores individuales en la alineación generalizada de interés. Esto ignora todos los efectos de interacción y supone que el desempeño de la alineación generalizada es equivalente a la suma de los desempeños individuales de los jugadores en la alineación.

2. Calcular el PM acumulado de la alineación generalizada, es decir, hallar la diferencia de anotación mientras esa combinación de jugadores está en el partido. Esto no incorpora ningún ajuste de alineación y es sensible a los patrones de sustitución de la misma manera que la estadística simple de PM.

Ambos enfoques tienen desventajas evidentes, y ninguno es capaz de clasificar las alineaciones generalizadas teniendo en cuenta los efectos de interacción. Para cerrar la brecha entre estos dos extremos, proponemos una solución para clasificar alineaciones y jugadores que se ajusta no solo a una alineación completa, sino a todas las combinaciones de jugadores de orden inferior. Nuestros métodos se basan en la representación como hipergrafo de una alineación, la cual, como demostramos, es una generalización de la matriz de diseño utilizada en el método APM convencional. El resultado es un enfoque unificado para clasificar simultáneamente cualquier alineación generalizada, incluyendo individuos, parejas y alineaciones completas. Además, nuestros métodos se prestan a visualizaciones interpretables que permiten identificar rápidamente las sinergias positivas y negativas entre grupos de jugadores de un equipo.

El resto del artículo está organizado de la siguiente manera. En la sección 2, revisamos los métodos relacionados en la literatura para clasificar alineaciones. A continuación, en la sección 3, presentamos los fundamentos matemáticos del APM, utilizado para clasificar a jugadores individuales. Al hacerlo, analizamos el APM de pares (una variante del APM que puede utilizarse para clasificar y ajustar pares de jugadores, pero que, en última instancia, resulta demasiado costoso computacionalmente para alineaciones generalizadas de orden superior). En la sección 4, repasamos la terminología y la notación necesarias de la teoría de grafos y, a continuación, establecemos la conexión entre el APM y los hipergrafos. Esto nos lleva al desarrollo de nuestros dos nuevos métodos de clasificación. Aplicamos estos nuevos métodos a 10 años de datos de la NBA, de 2012 a 2022, en la sección 5 y concluimos con una discusión en la sección 6 sobre nuestros métodos, sus limitaciones y posibles direcciones futuras.

2 Trabajos relacionados

Si bien no existen métodos para clasificar simultáneamente combinaciones de jugadores de orden inferior y alineaciones completas, se han realizado numerosas investigaciones sobre cómo medir la eficiencia de las alineaciones completas. Por ejemplo, Lechner y Vidar Gudmundsson (2012) adoptan una perspectiva basada en los recursos para elegir alineaciones óptimas en el fútbol y describen el tipo de «recursos humanos» que conducen a una creación de valor superior en un equipo. Maymin et al. (2013) introducen un «plus-minus» de habilidades para medir el desempeño de los individuos en ciertos aspectos del baloncesto, como el manejo del balón, los rebotes y la anotación. A continuación, los autores calculan las alineaciones óptimas midiendo las sinergias y seleccionando a los jugadores con conjuntos de habilidades complementarias. Grassetti et al. (2021) analizan cómo se puede utilizar el APM directamente para clasificar alineaciones completas: además de sumar los efectos individuales de los jugadores en una alineación determinada, los autores proponen un parámetro independiente para cada alineación, lo que constituye un «efecto de alineación». Barrientos et al. (2023) presentan un método bayesiano para cuantificar el alto grado de incertidumbre en las clasificaciones individuales y de alineaciones.

Existen algunos métodos de clasificación que utilizan técnicas de la teoría de redes. LinNet fue presentado en Pelechrinis (2018) como un enfoque para clasificar alineaciones mediante incrustaciones de redes. Se construye una red en la que las alineaciones son nodos; existe un arco dirigido $i \to j$ si la alineación i superó en puntuación a la alineación j, y el margen de puntuación correspondiente es el peso del arco. Para cada alineación, los autores calculan el APM promedio de los jugadores que la integran. A continuación, los autores incrustan esta red de alineaciones utilizando `node2vec` y los vectores latentes resultantes se utilizan como covariables en una regresión logística. La respuesta de la regresión es la diferencia en el APM promedio entre dos nodos, lo que permite a los autores inferir la probabilidad de que una alineación supere a otra. De manera similar, Ahmadalinezhad y Makrehchi (2020) utilizan redes de alineaciones para predecir el resultado de un enfrentamiento entre alineaciones rivales. Los autores introducen la métrica del inverso del cuadrado (ISM) como medida para predecir el desempeño de las alineaciones, con $\mathrm{ISM}(i, j) = \mathrm{D}(i)\mathrm{D}(j)/|\mathrm{LP}(i, j)|^2$, donde $\mathrm{D}(i)$ es el grado de la alineación i y $\mathrm{LP}(i, j)$ es la longitud del camino más corto entre las alineaciones i y j. Los autores demuestran que la ISM es más predictiva del desempeño que las incrustaciones `de node2vec`.

Si bien los enfoques mencionados reconocen implícitamente que evaluar una alineación no es tan sencillo como sumar las contribuciones de los jugadores individuales dentro de la alineación, no toman en cuenta el alcance completo de los efectos de interacción. Además, no pueden utilizarse para clasificar alineaciones generalizadas fuera de las alineaciones completas.

El método más similar al nuestro es el de Devlin y Uminsky (2020), que adopta un enfoque espectral. Los autores definen una *función de éxito* $f(L) = \mathrm{pm}_L$, donde L es una de las $\binom{15}{5}$ alineaciones de 5 jugadores de una plantilla de 15 y pm_L es el «plus-minus» bruto de la alineación. Se demuestra que la función de éxito se descompone ortogonalmente en las alineaciones generalizadas, lo que proporciona una medida natural de la contribución de cada alineación generalizada. La inferencia se realiza relacionando la función de éxito con el *grafo de Johnson*. Para tomar en cuenta el número de posesiones que una alineación juega junta, los autores normalizan sus resultados mediante el logaritmo del número de posesiones jugadas por cada alineación, lo que denominan *«contribución espectral por logaritmo de posesión» (SCLP)*. No existe una forma natural de ajustar el SCLP según el rival.

A diferencia del SCLP, utilizamos un enfoque basado en modelos mediante las herramientas conocidas del análisis de regresión. Nuestros resultados, ya sean valores ajustados o estimaciones de coeficientes, son fáciles de interpretar y pueden proporcionar estimaciones de error estándar y declaraciones de confianza. Además, mientras que el SCLP requiere datos de una plantilla estable de 15 personas, nuestros métodos pueden utilizarse para hacer predicciones sobre alineaciones no utilizadas y pueden tomar en cuenta a los compañeros de equipo que se incorporan, se retiran o son traspasados a lo largo de la temporada. Si bien tanto

Diferencia de puntaje	Tiempo (min)	A	B	C	D	E
3	3	1	1	1	0	0
2	3	1	1	0	1	0
-1	2	0	0	1	1	1
-2	1	0	1	0	1	1
0	1	1	1	0	0	1

Tabla 1: Ejemplo ilustrativo de un partido de baloncesto de 3 contra 3 de 10 minutos de duración. La tabla concatena el vector de respuesta, la diagonal de la matriz de tiempo y la matriz de diseño, es decir, [Y, diag(W), X].

A pesar de que las métricas proporcionan clasificaciones dentro de cada equipo, demostramos que nuestros resultados ofrecen, no obstante, una comparación precisa de las alineaciones generalizadas en toda la liga. Por último, tal como lo señalan los autores de Devlin y Uminsky (2020), los diversos métodos de calificación de jugadores y alineaciones generalizadas pueden considerarse complementarios: cada enfoque ofrece perspectivas distintas y, cuando se combinan, mejoran la toma de decisiones al brindar una comprensión más integral del desempeño de los equipos y los jugadores.

3 Plus-Minus ajustado

Para aislar y clasificar los efectos de los jugadores individuales, el plus-minus ajustado (APM) utiliza una regresión lineal múltiple. Sea X una matriz $n \times p$, donde n es el número de alineaciones únicas durante el período de tiempo considerado, p es el número de jugadores únicos, y $X_{ij} = 1$ si el jugador j estuvo en la alineación i y 0 en caso contrario. La variable de respuesta Y es el diferencial en la cancha (puntos anotados - puntos permitidos) para esa alineación. Suponiendo un modelo lineal en el que $\mathsf{E}[Y|X] = X\beta$, entonces, mediante los mínimos cuadrados ordinarios, el APM es el vector de valores de los coeficientes $\beta_{ols} = (X^T X)^{-1} X^T Y$ del modelo ajustado. Por lo tanto, β_{ols} representa la contribución de cada uno de los p jugadores, dados los demás jugadores del equipo, y puede utilizarse para clasificar el impacto de los jugadores.

Para ilustrar el APM, presentamos un ejemplo hipotético al que se hará referencia a lo largo del manuscrito. Imaginemos un equipo con 5 jugadores etiquetados de A a E, y un partido de 10 minutos con alineaciones de 3 jugadores. Los resultados de uno de estos partidos se resumen en la Tabla 1. En el modelo lineal descrito anteriormente, las columnas de jugadores (A:E) definen la matriz de diseño X y «Diferencia de puntaje» es el vector de respuesta
Y. Vemos que la primera alineación (A, B, C) fue la más exitosa con una diferencia de puntaje de +3, lo que indica que esta alineación superó al otro equipo por 3 puntos en total durante los 3 minutos que A, B y C jugaron juntos. También vemos que el jugador A tiene la puntuación PM más alta, de +5, la cual se puede calcular mediante el producto escalar $X_{\cdot A} \cdot Y$. Sin embargo, el jugador A siempre jugó con el jugador B, por lo que no queda claro cuál de los dos jugadores merece más crédito por los éxitos de sus alineaciones.

En nuestro ejemplo, los coeficientes estimados al realizar una regresión de Y sobre X, que se muestran en la Tabla 2, dan como resultado la siguiente clasificación de los jugadores (en orden de mejor a peor): A, C, B = D, E. Este modelo se ajusta perfectamente a los datos dado que $n = p = 5$, y las estimaciones de los coeficientes son muy sensibles a pequeñas perturbaciones en los datos. Además, la existencia de empates en la clasificación, como ocurre con los jugadores D y E, no es deseable. Las métricas APM más avanzadas incorporan tanto a los jugadores locales como a los visitantes (es decir, cada observación única es una alineación de un equipo contra el otro), utilizan una configuración de regresión penalizada para estabilizar las estimaciones (Sill 2010) e incorporan el tiempo de juego y estadísticas adicionales de la hoja de partido o calificaciones externas (Hvattum 2019). En nuestro ejemplo, tras utilizar la validación cruzada para elegir un

nivel adecuado de regularización, una regresión de cresta ponderada da como resultado la clasificación mejorada

Jugador	PM	$\hat{\beta}_{ols}$	$\hat{\beta}_r$	β^PAPM
A	5	2	1,64	0,254
B	3	0	0,35	0,253
C	2	1	0,90	0,101
D	-1	0	-0,12	-0,005
E	-3	-2	-1,78	-0,108

Tabla 2: PM, APM utilizando OLS, APM utilizando regresión ridge y PAPM para los jugadores A-E utilizando los datos de la Tabla 1.

esquema: A, C, B, D, E (véase $\hat{\beta}_r$ en la Tabla 2). Alternativamente, si se contara con información *a priori* sobre los jugadores de nuestro ejemplo, podríamos reformular la regresión de ridge en un marco bayesiano e incorporar esta información adicional sobre los jugadores en la distribución a priori (Matano et al. 2023).

Aunque es una métrica popular para clasificar a los jugadores, una desventaja del APM y sus variantes es que no se ajusta a las alineaciones generalizadas. Consideremos el escenario en el que dos jugadores se destacan cuando juegan juntos, pero tienen un desempeño menos efectivo cuando juegan por separado. El APM no logra captar este matiz y puede dar lugar a que ambos jugadores individuales sean clasificados cerca de la mediana, dependiendo de su frecuencia de juego juntos o por separado. Por otro lado, algunos jugadores que son excelentes individualmente pueden no jugar bien juntos si, por ejemplo, sus habilidades se superponen. Por lo tanto, es necesario tomar en cuenta las combinaciones de jugadores dentro de las alineaciones completas.

3.1 APM por pares

Un enfoque intuitivo y relativamente sencillo para tomar en cuenta las combinaciones de orden inferior en la construcción actual del APM consiste en agregar términos de interacción como nuevas columnas en la matriz de diseño. Siguiendo con nuestro ejemplo sencillo, podemos agregar $\binom{5}{2} = 10$ columnas adicionales a X, cada una de las cuales representa un par de jugadores. El vector de columna toma el valor 1 cuando ambos jugadores están en la alineación y 0 en caso contrario. Véase la Tabla 3 para un ejemplo. El vector de respuesta no cambia, y los coeficientes obtenidos al realizar una regresión *de Y* sobre *X* permiten clasificar simultáneamente a individuos y pares, al tiempo que se tienen en cuenta todos los demás jugadores y pares. Nos referimos a este método como «más-menos ajustado por pares» (PAPM).

Incluimos en la Tabla 2 los coeficientes del PAPM obtenidos mediante regresión ridge ponderada. Con este nuevo procedimiento de estimación, las clasificaciones individuales de los jugadores pueden variar en comparación con las estimaciones de $\hat{\beta}_r$, por ejemplo, el jugador B ahora supera al jugador C (aunque este caso puede deberse al hecho de que, como consecuencia de la regresión ridge, el jugador B recibe una mayor contribución simplemente por el hecho de aparecer en cuatro de las cinco alineaciones). Además, existe la ventaja adicional de clasificar los pares utilizando los coeficientes de regresión asociados con las columnas adicionales en la matriz de diseño. Para contextualizar, las clasificaciones de los pares de mejor a peor son AB, BC, AC, AD, BD y así sucesivamente.

Diferencia de puntuación	Tiempo (min)	A	B	C	D	E	AB	AC	AD	AE	BC	BD	BE	CD	CE	DE
3	3	1	1	1	0	0	1	1	0	0	1	0	0	0	0	0
2	3	1	1	0	1	0	1	0	1	0	0	1	0	0	0	0
-1	2	0	0	1	1	1	0	0	0	0	0	0	0	1	1	1
-2	1	0	1	0	1	1	0	0	0	0	0	1	1	0	0	1
0	1	1	1	0	0	1	1	0	0	1	0	0	1	0	0	0

Tabla 3: Tabla 1 con columnas adicionales para los pares de jugadores. Téngase en cuenta que solo se calculan los pares con tiempo de juego distinto de cero; es decir, las sumas de las columnas para cada par son todas positivas.

Cabe señalar que esta idea ya se mencionó en Macdonald (2011):

> *Al no incluir términos de interacción en el modelo, no tomamos en cuenta las interacciones entre los jugadores. La química entre dos compañeros de equipo en particular, por ejemplo, se ignora en el modelo. La inclusión de términos de interacción podría reducir los errores. Las desventajas de este tipo de regresión serían que requiere mucho más poder de cálculo y que los resultados serían más difíciles de interpretar.*

Como se mencionó, el inconveniente inmediato de este enfoque es su escalabilidad. El número de combinaciones posibles de jugadores se dispara a medida que consideramos alineaciones generalizadas más grandes, lo que da como resultado una matriz de diseño donde «$p >> n$». Se pueden utilizar técnicas de regularización para que la regresión sea computacionalmente factible, pero los resultados no son sostenibles para términos de interacción compuestos por más de dos jugadores. Aun así, exploramos este método en la Sección 5 al aplicar nuestros métodos propuestos a datos históricos de la NBA.

4 Hipergrafos

En esta sección, presentamos las redes, los hipergrafos y los grafos lineales, que son esenciales para los métodos que proponemos. Comenzamos relacionando la matriz de diseño del APM con un hipergrafo k-regular. Luego, introducimos una generalización de esto para abarcar todas las alineaciones generalizadas. Finalmente, describimos nuestros dos nuevos métodos.

4.1 Antecedentes

Los grafos, o redes, son objetos de datos relacionales compuestos por nodos (también conocidos como vértices) que están conectados por aristas. Las aristas representan diversos tipos de relaciones o interacciones entre nodos, y se pueden utilizar diversos métodos estadísticos para modelar y comprender las complejas dependencias capturadas por la red (Kolaczyk y Cs´ardi 2014). Dado que las alineaciones de los equipos están intrínsecamente interconectadas, las redes de datos de partidos y equipos son una representación natural a tener en cuenta al clasificar las alineaciones generalizadas.

Matemáticamente, una red es un grafo $G = (V, E)$ con el conjunto de nodos $V = \{1, 2, 3, ..., n\}$ y el conjunto de aristas $E \subset V \times V$. Las redes suelen representarse mediante una matriz de adyacencia $A \in \{0, 1\}^{n \times (n)}$, donde $A_{ij} = 1$ siempre que $(i, j) \in E$ y 0 en caso contrario. Otras representaciones matriciales importantes incluyen:

- el laplaciano del grafo: $L = D - A$, donde D es la matriz diagonal de grados, es decir, $D_{ii} = \sum_{j \in V} A_{ij}$
- la matriz de incidencia: *M,* que tiene una fila para cada nodo, una columna para cada arista de la red, y $M_{ij} = 1$ si el nodo i es incidente a la arista e_j.

Un hipergrafo amplía el concepto de grafo al permitir aristas, llamadas hiperaristas, entre más de dos nodos. Los hipergrafos son una representación natural de las alineaciones de equipos, donde los nodos son jugadores y las hiperaristas representan las alineaciones. La visualización del hipergrafo para nuestro ejemplo sencillo se encuentra en el centro de la Figura 1. Los nodos representan a los jugadores A-E y están conectados entre sí por hiperaristas que representan las alineaciones. Hemos coloreado las hiperaristas para una visualización más clara,
por ejemplo, el rojo (R) representa la alineación A-B-C, que aparece en la primera columna de la Tabla 1.

Es importante destacar que interpretamos la matriz de diseño de la Tabla 1 como la transpuesta de la matriz de incidencia de su hipergrafo. La Figura 1 ilustra esta conexión entre la matriz de diseño y el hipergrafo. Esta conexión entre el APM y los hipergrafos nos motiva a explorar más a fondo la posibilidad de un análisis de redes para fundamentar la clasificación de los jugadores y las alineaciones generalizadas.

Nodos (Jugadores)	**Ar os** R	**(Forma ción** Y	G	B	P
A	1	1	0	0	1
B	1	1	0	1	1
C	1	0	1	0	0
D	0	1	1	1	0
E	0	0	1	1	1

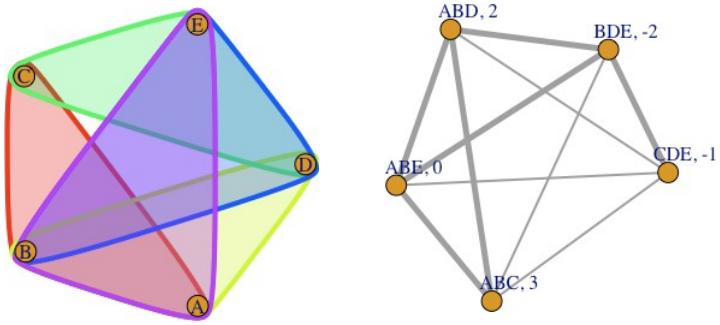

Figura 1: La matriz de incidencia *M* (izquierda) para el hipergrafo (centro) es exactamente la transpuesta de la matriz de diseño *X* para el APM que se presenta en la Tabla 1. Las hiperaristas están coloreadas para facilitar la visualización: R (rojo), Y (amarillo), G (verde), B (azul) y P (púrpura). El gráfico lineal (derecha) del hipergrafo (centro) se forma intercambiando los roles de los nodos y las hiperaristas.

Los métodos estadísticos que incorporan información de red a través de hipergrafos están menos desarrollados que los destinados a grafos estándar. Un enfoque común para integrar la estructura del hipergrafo en el análisis consiste en transformar el hipergrafo en un grafo estándar. Una de estas transformaciones es el grafo lineal del hipergrafo.

Un grafo lineal se construye al tratar cada hiperarista del hipergrafo original como un nodo en el nuevo grafo. Dos nodos del grafo lineal están conectados por una arista si sus hiperaristas correspondientes en el hipergrafo comparten al menos un nodo. Esta transformación nos permite analizar las relaciones entre hiperaristas en un marco más convencional basado en grafos. Para cuantificar la fuerza de estas conexiones, asignamos pesos a las aristas en el grafo lineal. Específicamente, utilizamos la similitud de Jaccard para medir el solapamiento entre dos hiperaristas. La similitud de Jaccard entre dos hiperaristas e_i y e_j viene dada por:

$$wij = \frac{|e_i \cap e_j|}{|e_i \cup e_j|},$$

donde e_i y e_j son los conjuntos de nodos que pertenecen a las hiperaristas correspondientes. Por ejemplo, en nuestro conjunto de datos de prueba (ilustrado en la Figura 1), consideremos las hiperaristas ABD (amarilla) y ABE (púrpura)

en el hipergrafo. En el grafo lineal correspondiente, estas hiperaristas se convierten en nodos, los cuales están conectados por una arista. El peso de esta arista se calcula utilizando la similitud de Jaccard: del conjunto combinado de 4 jugadores A, B, D y E, los jugadores A y B son comunes a ambos nodos, lo que da como resultado un peso de arista de $\frac{2}{4}$. Este esquema de ponderación refleja el grado de similitud entre las diferentes hiperaristas. Dado que estamos trabajando con un grafo ponderado, reemplazamos la matriz de adyacencia binaria por su contraparte ponderada, de tal manera que $A_{ij} = w_{ij}$ siempre que $(i, j) \in E$. Además, cabe señalar que, al utilizar la representación del grafo lineal, las diferencias de puntuación, Y, ahora están asociadas con los *nodos* del grafo lineal.

El hipergrafo y su gráfico lineal correspondiente, tal como se describen actualmente, se basan únicamente en alineaciones completas. Esto se conoce como un hipergrafo k-regular, en el que cada hiperarista conecta exactamente $k = 3$ nodos. Sin embargo, podemos ampliar nuestra representación para incluir combinaciones de jugadores de orden inferior mediante la introducción de hiperaristas adicionales. Nos referimos a esto como el *hipergrafo extendido*, y a la transpuesta de su matriz de incidencia como la *matriz de diseño APM extendida*. Continuando con nuestro ejemplo ilustrativo, agregamos filas adicionales a la Tabla 1 que describen los resultados agregados de los jugadores en pareja y en solitario, como se muestra en el caso del Jugador A, en la Tabla 4. Tenga en cuenta que no incluimos filas redundantes en la matriz; es decir, el emparejamiento A-B y el diferencial de puntuación no se duplican en los datos de alineaciones extendidas para el emparejamiento B-A. También creamos el gráfico de líneas correspondiente al hipergrafo extendido; ambos se muestran en la Figura 2. En la Figura 2, el gráfico de líneas (a la derecha) tiene un nodo para cada alineación generalizada, y las alineaciones generalizadas están conectadas mediante un arco ponderado basado en la similitud de Jaccard.

Diferencia de puntuación	Tiempo (min)	A	B	C	D	E
.	.	.	.	.	.	.
5	7	1	1	0	0	0
3	3	1	0	1	0	0
2	3	1	0	0	1	0
0	1	1	0	0	0	1
5	7	1	0	0	0	0
.	.	.	.	.	.	.
.	.	.	.	.	.	.

Tabla 4: Datos ampliados de las alineaciones de la Tabla 1 con alineaciones generalizadas. Aquí solo mostramos las filas adicionales correspondientes a todas las alineaciones que contienen al jugador A.

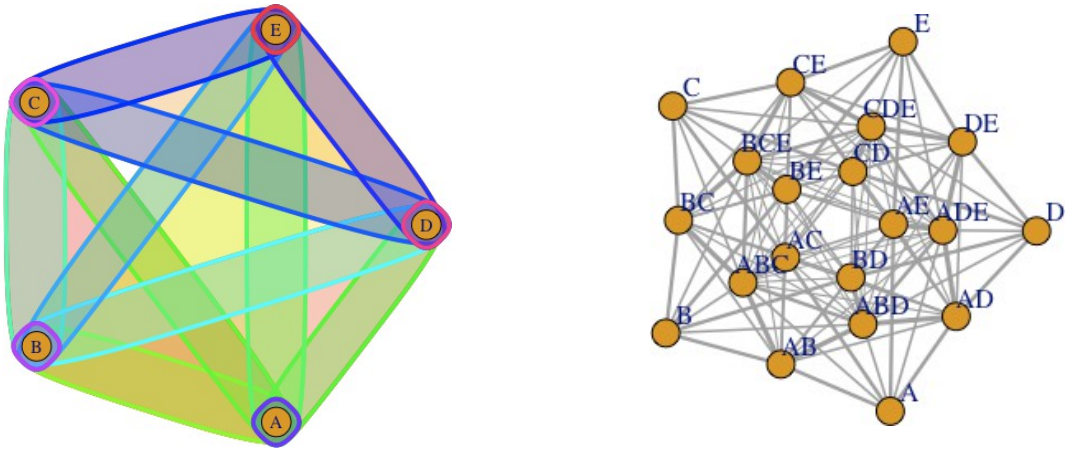

Figura 2: El hipergrafo ampliado (izquierda) definido por la Tabla 4 y su gráfico de líneas correspondiente (derecha).

4.2 Métodos

Aquí presentamos nuestros dos nuevos métodos que clasifican alineaciones generalizadas ajustadas para la alineación completa y todas las combinaciones de orden inferior de jugadores: el Plus-Minus ajustado al hipergrafo (HAPM) y el Plus-Minus ajustado al gráfico de líneas (LAPM). En resumen, el HAPM es una regresión que utiliza la matriz de diseño APM extendida, mientras que el LAPM emplea una regresión bayesiana que utiliza el gráfico de líneas del hipergrafo extendido con una distribución a priori que impone suavidad en los valores ajustados de alineaciones similares.

4.2.1 APM de hipergrafo

Como alternativa al PAPM que sea escalable para todas las alineaciones generalizadas, presentamos el HAPM. El HAPM es la misma regresión de cresta ponderada descrita en la Sección 3 para el APM, pero con la matriz de diseño original sustituida por la transpuesta de la matriz de incidencia del hipergrafo *extendido*. En este caso, las columnas de la matriz de diseño representan a cada jugador, las filas son combinaciones de jugadores y el elemento es 1 si ese jugador forma parte de la combinación de jugadores de esa fila. Es decir, X_{HAPM}es la nueva matriz de diseño donde $(X_{\text{HAPM}})_{ij}$= 1 si el jugador j forma parte de la combinación de jugadores representada en la fila i y 0 en caso contrario. Tenga en cuenta que si restringimos las filas únicamente a alineaciones completas, entonces esto es exactamente el APM ordinario (calculado a nivel de equipo) y la matriz de diseño es la transpuesta de la matriz de incidencia del hipergrafo k-regular (no extendido). Como antes, la respuesta es el más-menos bruto para una fila dada. Mediante la regresión ridge, obtenemos los coeficientes $\hat{\beta}_{\text{HAPM}}$a nivel de cada jugador que tienen en cuenta todas las alineaciones generalizadas incluidas en la matriz de diseño.

¿Podemos clasificar combinaciones de jugadores utilizando el HAPM? La respuesta es sí. Además de los coeficientes de regresión, que corresponden a los jugadores/columnas de nuestra matriz de diseño, contamos con los valores predichos $\hat{y}_{\text{HAPM}}$ que corresponden a las combinaciones/filas. Por lo tanto, contamos con una solución natural para clasificar combinaciones de cualquier tamaño. Por ejemplo, si queremos encontrar la mejor combinación de m jugadores, ordenamos los valores predichos $\hat{y}_{\text{HAPM}}$ entre todas las combinaciones cuyas sumas de las filas *de* X_{HAPM} sean iguales a m. Podemos utilizar este mismo enfoque para clasificar por separado parejas, tríos, etc.

Observación. *Para los individuos, podemos utilizar tanto los coeficientes $\hat{\beta}$ como los valores predichos y correspondientes a las sumas de las filas de X iguales a 1. Estos valores son equivalentes porque $\hat{y} = X\hat{\beta}$ y, para un individuo i, solo hay una columna distinta de cero, $X_{\cdot,i}$, correspondiente a ese individuo; por lo tanto, $\hat{y}_i = X_{\cdot,i}\hat{\beta} = \hat{\beta}_i$.*

Observación. *De manera similar, podemos utilizar los valores pronosticados y de un modelo de regresión APM para clasificar alineaciones completas. Sin embargo, el APM no puede utilizarse para obtener clasificaciones de ninguna combinación de jugadores de orden inferior.*

4.2.2 APM de grafos lineales

El HAPM utiliza implícitamente la representación de hipergrafo, pero no considera explícitamente los patrones de conectividad dentro del hipergrafo. Para abordar esto, nos inspiramos en el análisis de datos funcionales (Ramsay y Silverman 2002) y proponemos un enfoque de regresión bayesiana utilizando el grafo lineal del hipergrafo extendido. Este enfoque se asemeja a la regresión de kernel en un grafo (Smola y Kondor 2003), lo que nos permite extender las técnicas basadas en regresión a datos indexados en grafos, donde los modelos y supuestos convencionales podrían no ser aplicables. En nuestro caso, permite clasificar a jugadores individuales y alineaciones generalizadas, al tiempo que se consideran *todas* las combinaciones activas de jugadores en un equipo.

Al utilizar la representación de un equipo mediante un gráfico de líneas extendido, consideramos el "plus-minus" bruto asociado a cada nodo como una variable de respuesta aleatoria Y_v. Nuestro objetivo es predecir este valor utilizando la información codificada en la red y, a continuación, clasificar a los jugadores y las alineaciones generalizadas con base en estas predicciones. Utilizamos un modelo de regresión bayesiano que se especifica de la siguiente manera:

$$Y_v / \beta \overset{ind}{\sim} N(\beta_v, \sigma^2)$$
$$\beta \sim N(0, \lambda^{-1} L_w^{-1})$$

donde β_v es una «interceptación» indexada por vértice, σ es la desviación estándar de la distribución normal asumida, L_w es el laplaciano ponderado del grafo introducido en la sección 4.1, y λ es un parámetro de regularización. Aquí, la estimación máxima a posteriori (MAP) para β es

$$\hat{\beta}_{\text{LAPM}} = \text{argmax}_{\beta} \quad \ell(\beta; Y) - \frac{\lambda}{2} \beta^T L_w \beta$$

lo cual muestra que buscamos estimaciones de β_v que equilibren la representatividad con respecto a nuestros datos observados en la log-verosimilitud $\ell(\beta; Y)$ con información previa sobre la conectividad de la red capturada por el laplaciano. Nos referimos a esto como «más-menos ajustado al grafo lineal» (LAPM).

Nuestra elección del laplaciano del grafo está diseñada para aprovechar la información de la red a fin de informar al modelo y hacer que los valores predichos sean suaves con respecto a la topología del grafo lineal. Es decir, a los nodos se les asignan valores basados en su conectividad en la red y los nodos adyacentes tendrán valores predichos similares. De hecho, el logaritmo de la distribución a priori puede expandirse como

$$\beta^T L_W \beta = \sum_{(i,j) \in E} w_{ij} (\beta_i - \beta_j)^2$$

lo que demuestra que el término penaliza la suma ponderada de las diferencias al cuadrado para los coeficientes de los vértices adyacentes en la red (Kolaczyk y Cs´ardi 2014). Además, los pares de nodos con mayores pesos de arista

, correspondientes a alineaciones generalizadas más similares, se verán obligados a tener valores predichos más similares.

Dado que $L_w$es una matriz simétrica, cumple con la descomposición en valores propios $L_w = \Phi\Xi\Phi$, por lo que podemos representar β mediante una expansión en base a los vectores propios de L_w, definiendo $\beta = \Phi\theta$ (Upton y Carvalho 2024). En resumen, utilizamos los vectores propios del laplaciano como variables predictoras, hallamos un conjunto de coeficientes correspondientes $\hat{\theta}$ mediante regresión lineal bayesiana y, luego, realizamos una multiplicación de matriz por vector para resolver las intersecciones indexadas por vértices $\hat{\beta}_v = Y_v$. No es necesario utilizar el conjunto completo de vectores propios para representar β. En su lugar, podemos extraer la mayor parte de la información de $L_w$mediante una representación de bajo orden tal que $\beta = \Phi_{1:\tau}\theta$, donde $\Phi_{1:\tau}$representa los primeros τ vectores propios (ordenados por los valores propios $\xi_1 < \cdots < \xi_\tau$). En la práctica, seleccionamos τ basándonos en un método de «codo», examinando las diferencias secuenciales en el tamaño de ξ_i .

Para tener una idea más clara sobre el LAPM, consideremos al jugador C en el gráfico lineal de la Figura 2. El jugador C está representado por su propio nodo, el cual también está conectado a los nodos BC, AC, CD y CE (que representan parejas) y a ABC y CDE (que representan alineaciones completas), ya que el jugador C forma parte de esas alineaciones generalizadas. Por lo tanto, el valor predicho por el LAPM para C se verá afectado, a través de la distribución a priori que incorpora el laplaciano, por los valores predichos o el desempeño de todos los nodos mencionados anteriormente.

De manera similar al HAPM, podemos clasificar combinaciones de jugadores de cualquier tamaño utilizando el LAPM. En este caso, cada vértice o nodo, que corresponde a una alineación generalizada, tiene su propio coeficiente $\hat{\beta}_v$. Los coeficientes correspondientes a alineaciones generalizadas del mismo tamaño pueden ordenarse y clasificarse. También podemos utilizar la representación en forma de grafo lineal del hipergrafo extendido para visualizar la conectividad entre los jugadores y las alineaciones generalizadas.

5 Análisis de la NBA 2012-2022

5.1 Procesamiento de datos

En esta sección, aplicamos PAPM, HAPM y LAPM a los datos de la NBA de 2012 a 2022. Los datos brutos de jugada por jugada se pueden adquirir en `https://www.bigdataball.com/`. Nuestro código se encuentra en el repositorio de GitHub `njosephs/HAPM`.

Nuestro proceso de análisis de datos es el siguiente. Para cada equipo, comenzamos calculando los datos brutos de plus-minus (PM) de cada partido. Luego, agregamos el PM de cada temporada; es decir, calculamos X, W e Y, donde las filas de X representan las alineaciones únicas, W es el tiempo promedio por partido que una alineación determinada jugó junta, y Y es el PM de esa alineación a lo largo de la temporada. Limitamos nuestro análisis para incluir únicamente a los jugadores con al menos 10,000 segundos de tiempo de juego, lo que equivale a aproximadamente 2 minutos por partido. A modo de comparación, el tiempo mínimo para ser elegible para el premio All-Pro se modificó en 2023 a 65 partidos y 20 minutos por partido, lo que equivale a 78,000 segundos. Para simplificar, no realizamos ajustes por las temporadas acortadas debido a la COVID (2019-2020 y 2020-2021), lo cual, dado el menor tamaño de la muestra, dará lugar a una menor variación entre los jugadores en las estadísticas de APM a nivel de liga.

Con el fin de comparar nuestras métricas con las versiones más comunes del APM, también calculamos X, W e Y en toda la liga para cada temporada, en lugar de hacerlo a nivel de equipo. En este caso, X tiene una columna para cada jugador de la liga y cada «alineación» está compuesta por diez jugadores, repartidos entre dos

equipos, que comparten tiempo en la cancha. Incorporamos la defensa haciendo que los valores de X sean ±1 dependiendo de si el jugador está en el equipo local o visitante. Es decir,

$$X_{ij} = \begin{cases} +1 & \text{si el jugador } i \text{ está en la alineación } j \text{ del equipo local} \\ -1 & \text{si el jugador } i \text{ está en la alineación } j \text{ del equipo visitante} \\ 0 & \text{de lo contrario} \end{cases}$$

en el que cada fila de X tiene exactamente cinco entradas de +1 y cinco entradas de -1. Al establecer Y como el PM con respecto al equipo local, las entradas negativas de X aseguran que $Y_j < 0$ corresponda a una alineación visitante con un PM positivo. Nos referimos a estas métricas a nivel de liga con defensa como APM de liga y PAPM de liga, y a nivel de equipo sin defensa como APM y PAPM, respectivamente.

Observación. *Nuestros métodos, HAPM y LAPM, se calculan a nivel de equipo y no incorporan a los jugadores rivales, ya que esto requeriría algún concepto de «aristas negativas». En consecuencia, las respuestas para HAPM y LAPM (así como para APM y PAPM) representan los puntos netos a nivel de temporada para una alineación generalizada, sin considerar a los jugadores rivales en la cancha. Por el contrario, las respuestas para APM de liga y PAPM de liga tienen en cuenta tanto los puntos netos a nivel de temporada de una alineación generalizada como el conjunto específico de oponentes. A pesar de esta distinción, aún podemos realizar comparaciones a nivel de liga al agregar los valores ajustados entre los equipos, tal como se describe en la sección 5.2.*

Para todos los modelos de regresión ridge (APM, PAPM y HAPM), elegimos el parámetro de regularización λ que minimiza el error de validación cruzada, que es una de las opciones predeterminadas del paquete `glmnet` (Hastie et al. 2021).

Por último, para el análisis del estudio de caso, exploramos la variabilidad en los valores ajustados de HAPM y LAPM, junto con la incertidumbre implícita en sus clasificaciones. Para HAPM, realizamos un bootstrap mediante muestreo con reemplazo de las filas de la matriz de diseño. Para cada muestra de bootstrap, ajustamos un modelo de regresión ridge y utilizamos el modelo para realizar predicciones sobre todas las alineaciones generalizadas. Examinamos y presentamos la variación en los valores ajustados de HAPM a través de las muestras de bootstrap. También clasificamos los valores ajustados dentro de combinaciones del mismo tamaño (individuos, pares, etc.), lo que proporciona una estimación de la incertidumbre en la clasificación. Para el LAPM, tomamos muestras de las distribuciones a posteriori de los coeficientes utilizando un algoritmo de Langevin ajustado por Metropolis. Los detalles se proporcionan en el Apéndice A.

5.2 Correlación de rangos

La evaluación de las clasificaciones de los jugadores es, en última instancia, cualitativa, ya que no existe un concepto de «verdad fundamental». Sin embargo, como comparación de referencia, podemos ver qué tan estrechamente se correlacionan nuestras clasificaciones con aquellas basadas en métricas avanzadas como el «box score plus-minus» (BPM), el «valor sobre el jugador de reemplazo» (VORP), el «índice de eficiencia del jugador» (PER) y las «acciones ganadoras por 48 minutos» (WS.48) (*Basketball-Reference* 2024). Lo ideal sería que las clasificaciones individuales que obtenemos con nuestros métodos coincidan en general con los métodos conocidos diseñados para clasificar a los jugadores, al tiempo que proporcionen clasificaciones para todas las combinaciones de jugadores.

Para cada año entre 2012 y 2022, calculamos la correlación de rangos de Spearman entre cada método de clasificación y la métrica avanzada en cuestión. Los resultados se presentan en la Figura 3. Para los métodos calculados a partir de datos de equipo (APM, PAPM, HAPM y LAPM), los valores ajustados y los coeficientes de todos los equipos se combinan y clasifican, de modo que todas las correlaciones se calculan a nivel de liga. Las correlaciones positivas más altas implican una mayor concordancia con las clasificaciones de referencia, y los diagramas de caja muestran la variabilidad en las correlaciones a lo largo de los años.

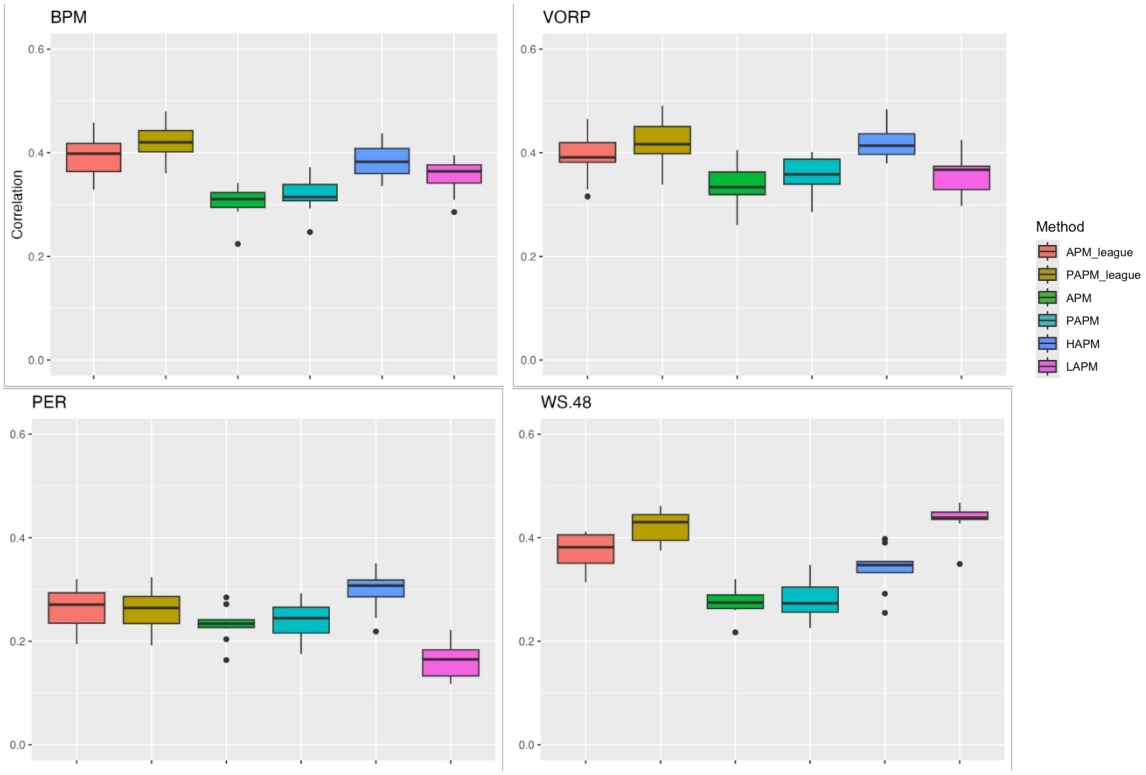

Figura 3: Correlación de rangos de Spearman para cada método en comparación con cada métrica avanzada. Los diagramas de caja muestran la variabilidad a lo largo de los años 2012-2022.

En la Figura 3, vemos que el HAPM es mejor que el APM, es decir, que concuerda más con el BPM, el PER y el VORP. Por el contrario, el LAPM es el que presenta una mayor correlación con el WS.48. Esto es importante porque el WS.48 toma en cuenta las contribuciones ofensivas y defensivas (a diferencia del PER, que es principalmente una medida de la producción ofensiva y la eficiencia anotadora), incorpora el tiempo de juego y está estrechamente relacionado con el desempeño general y el récord de victorias del equipo correspondiente.

También podemos observar lo que se pierde al alejarnos del APM de liga, que se modela a nivel de liga y se ajusta para la defensa. Al desplazarnos de izquierda a derecha entre los métodos, vemos que el PAPM de liga es, en general, mejor que el APM de liga para clasificar a los individuos, lo que demuestra que agregar términos de interacción puede mejorar el desempeño del modelo. Sin embargo, dado que incluir columnas de pares adicionales en la matriz de diseño requiere una mayor regularización (es decir, la contracción de todos los coeficientes), la mejora no es enorme. También observamos que calcular el APM a nivel de equipo es menos eficaz que a nivel de liga, lo que hace que el desempeño del HAPM y el LAPM sea aún más notable.

A partir de estas comparaciones, observamos que HAPM y LAPM se alinean con métricas avanzadas, así como con el APM de liga, a pesar de que no incorporan explícitamente consideraciones defensivas ni se calculan a nivel de liga. Además, HAPM y LAPM ofrecen clasificaciones simultáneas para todas las alineaciones generalizadas y son más robustas ante la elección del parámetro de penalización.

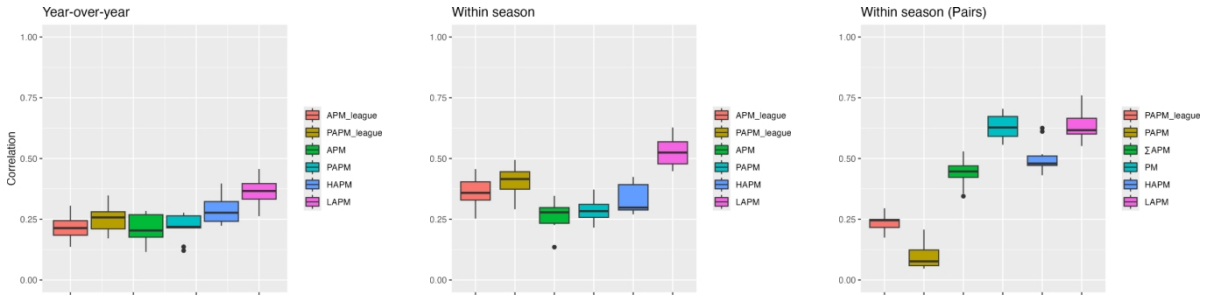

Figura 4: Correlación de rangos de Spearman para cada método año tras año (izquierda), dentro del mismo año con respecto al PM observado para individuos (centro) y dentro del mismo año con respecto al PM observado para parejas (derecha) a lo largo de los años 2012-2022.

5.3 Precisión predictiva

Además de analizar la concordancia entre nuestros métodos y varios análisis avanzados, podemos observar qué tan predictivas son nuestras métricas respecto al desempeño futuro de los jugadores, las parejas o las alineaciones generalizadas. En la Figura 4 (izquierda) mostramos las correlaciones de rangos interanuales de los métodos APM para jugadores individuales. Para los años t y $t + 1$, consideramos únicamente a los jugadores que cumplieron con los requisitos para ser incluidos en ambos años, pero permitimos que aquellos jugadores que cambien de equipo sean incluidos. Observamos que HAPM y LAPM presentan correlaciones más altas que las otras variantes de APM, lo que sugiere que HAPM y LAPM son métricas más estables. Sin embargo, notamos que los valores de correlación de rangos no son particularmente altos, por lo que claramente se producen cambios en las clasificaciones a lo largo del tiempo, algo que es de esperarse.

Para evaluar la capacidad de predicción dentro de una misma temporada, dividimos cada temporada en dos mitades y evaluamos qué tan bien predicen las métricas los datos de la segunda mitad de la temporada cuando se ajustan a los datos de la primera mitad. En la Figura 4 (centro), vemos que las predicciones de LAPM presentan la mayor correlación de rangos con los valores observados de «más-menos» de la segunda mitad de la temporada. Sin embargo, esta evaluación interpreta el PM como la verdad de referencia, lo cual es un tanto problemático dado que nuestro argumento inicial es que el PM no refleja completamente el talento de un jugador individual. Por lo tanto, también incluimos en el apéndice (Figura A1) la correlación de rangos entre las mitades de la temporada para cada métrica. Esto sugiere nuevamente que HAPM y LAPM son las métricas más estables a lo largo del tiempo. Es decir, incorporar todas las alineaciones generalizadas en la metodología de modelado (como lo hacen HAPM y LAPM) parece ayudar a las predicciones de clasificación de los jugadores.

Realizamos evaluaciones similares en los pares clasificados. Además de PAPM, HAPM y LAPM, consideramos los dos enfoques ingenuos mencionados en la introducción. En particular, denotamos con ΣAPM y PM los métodos que suman el APM de todos los individuos y el PM acumulativo, respectivamente, para la alineación generalizada de interés (en este caso, los pares). Una vez más, observamos que LAPM es el método más predictivo, y que HAPM también presenta un buen desempeño. Curiosamente, el PM es muy predictivo para los pares, pero como señalamos, este método de evaluación considera el PM como la verdad de referencia; por lo tanto, si existen dependencias en, por ejemplo, los patrones de sustitución, es probable que los valores del PM de la segunda mitad también se vean afectados, lo que podría estar inflando artificialmente la correlación. Al igual que antes, incluimos la correlación entre las mitades de la temporada para cada métrica en la Figura A1.

Nombre del jugador	Minutos	PM	HAPM (CI de rango)	LAPM, rango (IC de rango)
Joel Embiid	2295	365	75,0 (1 - 1)	166,7, 1 (1 - 1)
James Harden	793	151	38,8 (2 - 3)	73,9, 4 (4 - 5)
Tyrese Maxey	2648	192	27,8 (3 - 4)	94,2, 2 (2 - 3)
Tobias Harris	2542	170	25,6 (3 - 4)	88,6, 3 (3 - 3)
George Niang	1742	69	0,8 (5 - 8)	55,4, 8 (7 - 9)
Danny Green	1349	77	-0,1 (5 - 9)	56,8, 7 (6 - 10)
Isaiah Joe	609	23	-2,2 (6 - 8)	48,4, (8 - 12)
Charles Bassey	168	-34	-4,3 (7 - 10)	45,1, (9 - 14)

Tabla 5: Los ocho mejores jugadores de los Sixers en la temporada 2021-22 según el HAPM (e intervalos de confianza del 50 % para el rango implícito).

5.4 Estudio de caso

En esta sección, ofrecemos una evaluación cualitativa de nuestros métodos centrándonos en los 76ers de Filadelfia de la temporada 2021-22. Este año es notable porque los Sixers adquirieron a la superestrella James Harden a mitad de temporada. Esto sirve como una prueba de robustez para ver si nuestros métodos detectan el valor de Harden a pesar de que solo jugó una fracción de los partidos y, por lo tanto, tiene un PM artificialmente bajo. A pesar de su histórica capacidad anotadora, la temporada 2021-22 continúa la transición de Harden hacia un rol de facilitador, por lo que deberíamos esperar que aparezca entre los primeros puestos de la clasificación. La plantilla de los Sixers también incluye a Joel Embiid, quien lideró la liga en anotación y quedó en segundo lugar en la votación al MVP por segundo año consecutivo, así como al jugador de segundo año Tyrese Maxey, quien pasó a ser titular y desde entonces se ha convertido en un All-Star.

En la Tabla 5 mostramos a los ocho mejores jugadores individuales según el HAPM. Presentamos su HAPM y LAPM junto con los intervalos de confianza del 50 % para el rango implícito. La distribución completa de los valores de HAPM/LAPM se presenta en la Figura A2 del apéndice. Como era de esperarse, vemos que los cuatro mejores jugadores son Embiid, Harden, Maxey y Tobias Harris, un exseleccionado en la primera ronda del draft. Es importante destacar que, a pesar de tener solo un PM de 151, Harden es identificado como el segundo mejor jugador según el HAPM. Aunque existen correlaciones positivas de rango entre nuestras métricas y el PM (0,68 y 0,85 para el HAPM y el LAPM, respectivamente), al representarlas gráficamente frente al PM en la Figura 5, podemos identificar a los jugadores que podrían estar sobrevalorados o subvalorados si nos basamos únicamente en el PM.

Registramos las diez mejores parejas según el HAPM en la Tabla 6 y las visualizamos en la Figura 6. Las correlaciones de rango con el PM son de 0,61 y 0,46 para el HAPM y el LAPM, respectivamente. Aquí vemos que Embiid no solo es un gran jugador individual, sino que forma parte de las nueve mejores parejas según el HAPM (y de siete de las diez mejores parejas según el LAPM). Esto concuerda con la reputación de Embiid como jugador capaz de pasar el balón cuando se enfrenta a una doble marca. Además, a pesar de haber jugado juntos solo 600 minutos en total, tanto el HAPM como el LAPM reconocen la exitosa combinación de Embiid y Harden. Tal como esperábamos, nuestras métricas identifican a Harden como un buen compañero de equipo, ya que forma parte de tres de las seis mejores parejas tanto para el HAPM como para el LAPM.

Curiosamente, observamos clasificaciones altas para las parejas formadas por Embiid y Andre Drummond (la novena mejor pareja según HAPM y la decimosexta mejor según LAPM, de entre 96 parejas elegibles) y Embiid y Matisse Thybulle (13.ª/5.ª según HAPM/LAPM), a pesar de que sus PM son de solo 5 y 82, respectivamente. Esto se explica por la excelente combinación defensiva de Embiid con Drummond y Thybulle, que ambos métodos son capaces de detectar. Como era de esperarse, una

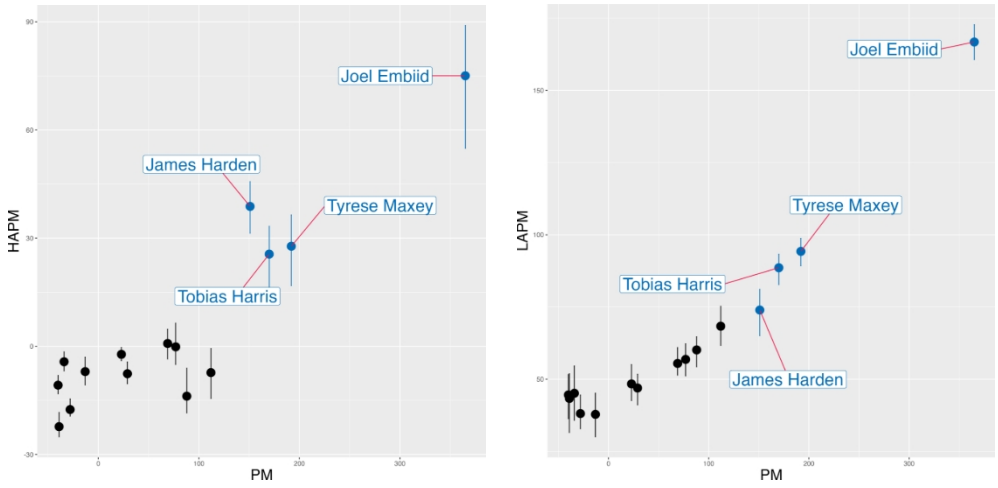

Figura 5: HAPM (izquierda) y LAPM (derecha) para jugadores individuales de los Sixers en 2021-22. Las barras de error en los ejes y representan intervalos de confianza del rango intercuartílico.

Pareja de jugadores	PM	HAPM (IC de rango)	LAPM, Rango, (IC de rango)
James Harden: Joel Embiid	193	113,8 (1 - 2)	67,1, 1 (2 - 9)
Joel Embiid: Tyrese Maxey	268	102,8 (1 - 3)	54,5, 10 (20 - 26)
Joel Embiid: Tobias Harris	256	100,6 (2 - 4)	55,6, 8 (17 - 23)
Georges Niang: Joel Embiid	133	75,8 (5 - 9)	53,5, 12 (26 - 33)
Danny Green: Joel Embiid	171	74,9 (5 - 9)	65,9, 2 (2 - 9)
Isaiah Joe: Joel Embiid	25	72,8 (6 - 9)	53,1, 15 (13 - 78)
Andre Drummond: Joel Embiid	5	68,0 (7 - 14)	53,1, 16 (13 - 79)
Joel Embiid: Seth Curry	131	67,7 (8 - 12)	64,5, 3 (3 - 10)
Furkan Korkmaz: Joel Embiid	108	67,4 (8 - 13)	54,7 (19 - 28)
James Harden: Tyrese Maxey	144	66,5 (4 - 13)	59,4, 6 (6 - 24)

Tabla 6: Las diez mejores parejas de los Sixers en 2021-22 según el HAPM (e intervalos de confianza del 50 % para el rango implícito).

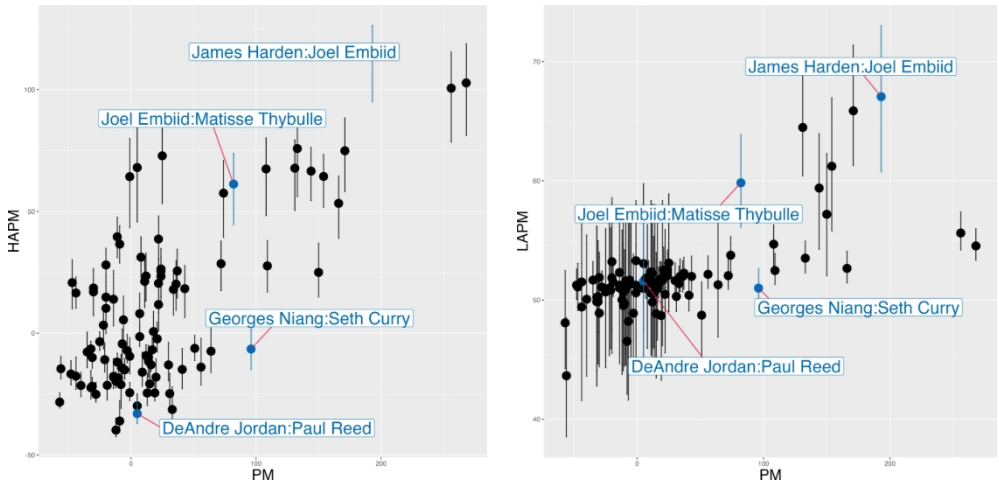

Figura 6: HAPM (izquierda) y LAPM (derecha) para las parejas de los Sixers en 2021-22. Las barras de error en los ejes y representan intervalos de confianza del rango intercuartílico.

La pareja con peor clasificación según el HAPM (como se muestra en la Figura 6) es la de Deandre Jordan y Paul Reed, ambos pívots con habilidades que se superponen. También resulta interesante que las dos mejores parejas según el PM (Embiid y Maxey, y Embiid y Harris) tengan clasificaciones relativamente bajas (10.º y 8.º, respectivamente) según el LAPM. Esto podría sugerir que el alto PM de estas parejas se puede atribuir al éxito individual de los jugadores o al éxito de alineaciones generalizadas de orden superior (por ejemplo, Embiid y Harris juegan juntos en los tríos clasificados en los puestos 3.º, 9.º, 13.º y 14.º según el LAPM).

Por último, mostramos que la conexión entre el HAPM, el LAPM y los grafos puede aprovecharse para crear visualizaciones informativas. La figura 7 muestra los gráficos de líneas basados en las 15 mejores parejas (izquierda) y tríos (derecha) según el HAPM. Los nodos azules representan a los jugadores individuales, mientras que los nodos rojos corresponden a parejas o tríos. El tamaño de los nodos es proporcional a su HAPM, y existe un borde entre el nodo de un jugador y el de una pareja o trío si ese jugador pertenece a la alineación generalizada en cuestión. Por ejemplo, la mejor pareja (marcada con el número 1) está conectada a los nodos de Embiid y Harden, mientras que el mejor trío está conectado a Embiid, Harden y Maxey. La disposición de los nodos se determina mediante el algoritmo de Fruchterman-Reingold, cuyo objetivo es generar automáticamente diseños de red visualmente atractivos al distribuir los nodos de manera uniforme y minimizar los cruces de aristas.

Una conclusión inmediata es el papel central de Embiid, ya que forma parte de 12 de las 15 mejores parejas y de los 15 mejores tríos según el HAPM. En ambas visualizaciones, se encuentra en el centro de la red. Los análisis exploratorios de otros equipos y otros años revelan que esto es muy común; las superestrellas son los nodos más centrales en las visualizaciones (como también se muestra para los Boston Celtics en la Figura A4 del apéndice). Una investigación más profunda revela que los nodos de parejas que son más grandes que uno o ambos nodos de jugadores (Embiid y Danny Green; Embiid y Thybulle; Embiid y Seth Curry; Embiid y Shake Milton) pueden representar posibles sinergias, mientras que los nodos de parejas que son más pequeños que los nodos de jugadores (Embiid e Isaiah Joe; Harris y Maxey) podrían indicar combinaciones ineficientes.

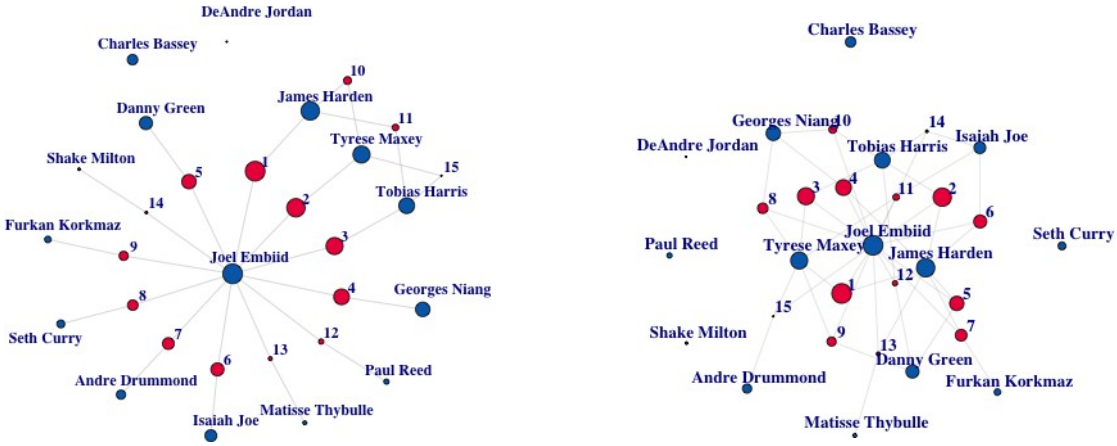

Figura 7: Visualización en gráfico de líneas de las clasificaciones HAPM de jugador/pareja (izquierda) y jugador/trío (derecha) para el PHI 2021-22. El tamaño de los nodos corresponde a la clasificación dentro de los individuos/parejas/tríos. Los nodos azules representan a los jugadores, y los nodos rojos, etiquetados con el rango, representan la pareja o el trío.

6 Discusión

En este artículo, proponemos un nuevo marco para clasificar a los jugadores individuales utilizando datos de plus-minus, al tiempo que clasificamos simultáneamente todas *las alineaciones generalizadas*. Demostramos que nuestros métodos, HAPM y LAPM, presentan una correlación similar o mayor con las métricas avanzadas para clasificar a los jugadores individuales que el APM convencional. También presentamos un estudio de caso sobre los 76ers de Filadelfia en la temporada 2021-22 que aparentemente identifica a los mejores jugadores individuales, parejas y tríos. En términos de utilidad, los entrenadores pueden identificar combinaciones de jugadores con bajo o alto rendimiento a mitad de temporada, ajustar sus alineaciones en consecuencia y evaluar el impacto en el desempeño del equipo. Además, las visualizaciones de red ilustran estas interacciones entre jugadores, resaltando directamente qué combinaciones impulsan el éxito o necesitan mejoras.

Hay algunos aspectos importantes que cabe destacar sobre nuestros métodos. En primer lugar, como se mencionó anteriormente, el PM, el APM y sus variantes —incluidos nuestros HAPM y LAPM propuestos— están altamente correlacionados con el porcentaje de victorias de un equipo. Esto no es intrínsecamente malo, ya que ganar es importante, pero tampoco es sorprendente, pues estos métodos solo utilizan datos de plus-minus, mientras que las métricas avanzadas emplean muchas covariables. El HAPM y el LAPM ofrecen una mejora respecto al APM en cuanto a las clasificaciones individuales, según se mide por la correlación con las métricas avanzadas, *a pesar de utilizar únicamente datos de plus-minus*.

Hay margen para refinar nuestros métodos, ya que algunas decisiones en el procesamiento de datos se tomaron por conveniencia. Por ejemplo, no registramos el PM con exactitud para las sustituciones que ocurren durante los tiros libres. También elegimos la similitud de Jaccard para definir las ponderaciones del grafo lineal del hipergrafo, pero se podrían investigar otras medidas de similitud. En cuanto al ajuste del modelo, utilizamos la regresión ridge por simplicidad y para compararla con las métricas de baloncesto que se publican habitualmente, pero no reflexionamos a fondo sobre la elección *de* λ. De manera similar, con el LAPM, una investigación más exhaustiva de la conexión entre la expansión del rango de la base (capturada por τ) y λ

podría conducir a una mejora en

capacidades predictivas.

Existen varias líneas de investigación futuras. Aquí presentamos dos nuevas métricas, LAPM y HAPM, para clasificar alineaciones generalizadas. Si bien comparamos sus resultados y señalamos las diferencias teóricas entre los dos enfoques, no intentamos comprender la causa de la (des)concordancia entre las métricas. Esto podría ser un ejercicio caso por caso que arrojara luz sobre el funcionamiento interno de cualquier equipo. Además, si bien es sencillo extender HAPM y LAPM a otras variantes de APM que tengan en cuenta otras estadísticas que no figuran en el marcador (Kubatko et al. 2007), no resulta tan obvio cómo incorporar la defensa en HAPM y LAPM. Nuestro trabajo demuestra que HAPM y LAPM pueden lograr resultados comparables a los de las métricas calculadas a nivel de liga incluso sin incorporar la defensa, pero esta es una dirección natural para el futuro.

Referencias

Ahmadalinezhad, M. y Makrehchi, M. (2020), «Predicción del desempeño de las alineaciones de baloncesto mediante el análisis de redes multivisión centrado en los enlaces», *Social Network Analysis and Mining* **10**, 1–11.

Barrientos, A. F., Sen, D., Page, G. L. y Dunson, D. B. (2023), «Inferencias bayesianas sobre clasificaciones y ordenamientos inciertos: aplicación a la clasificación de jugadores y alineaciones», *Bayesian Analysis* **18**(3), 777–806.

Basketball-Reference (2024), *https://www.basketball-reference.com*.

Devlin, S. y Uminsky, D. (2020), «Identificación de las contribuciones grupales en las alineaciones de la NBA mediante análisis espectral», *Journal of Sports Analytics* **6**(3), 215–234.

Girolami, M. y Calderhead, B. (2011), «Métodos de Monte Carlo de Langevin y hamiltonianos en variedades de Riemann», *Journal of the Royal Statistical Society Series B: Statistical Methodology* **73**(2), 123–214.

Grassetti, L., Bellio, R., Di Gaspero, L., Fonseca, G. y Vidoni, P. (2021), «Un análisis plus-minus ajustado y regularizado ampliado para la gestión de alineaciones en el baloncesto utilizando datos jugada por jugada», *IMA Journal of Management Mathematics* **32**(4), 385–409.

Hastie, T., Qian, J. y Tay, K. (2021), «Una introducción a glmnet», *CRAN R Repositary* **5**, 1–35.

Hvattum, L. M. (2019), «Una revisión exhaustiva de las calificaciones de más-menos para evaluar a jugadores individuales en deportes de equipo».

Kolaczyk, E. D. y Cs´ardi, G. (2014), *Análisis estadístico de datos de redes con R*, vol. 65, Springer.

Kubatko, J., Oliver, D., Pelton, K. y Rosenbaum, D. T. (2007), «Un punto de partida para analizar las estadísticas del baloncesto», *Journal of quantitative analysis in sports* **3**(3).

Lechner, C. y Vidar Gudmundsson, S. (2012), «Creación de valor superior en equipos deportivos: recursos y experiencia gerencial», *M@ n@ gement* (3), 284–312.

Macdonald, B. (2011), «Una estadística de plus-minus ajustada basada en regresión para jugadores de la NHL», *Journal of Quantitative Analysis in Sports* **7**(3).

Matano, F., Richardson, L., Pospisil, T., Politsch, C. A. y Qin, J. (2023), «Ampliación del «plus-minus» ajustado en el fútbol con las calificaciones de la FIFA», *Journal of Quantitative Analysis in Sports* **19**(1), 43–49. **URL:** *https://doi.org/10.1515/jqas-2021-0005*

Maymin, A., Maymin, P. y Shen, E. (2013), «La química de la NBA: sinergias positivas y negativas en el baloncesto», *International Journal of Computer Science in Sport, diciembre*.

Pelechrinis, K. (2018), «Linnet: evaluación probabilística de alineaciones mediante la incrustación de redes», *en* «Conferencia Europea Conjunta sobre Aprendizaje Automático y Descubrimiento de Conocimiento en Bases de Datos», Springer,
pp. 20–36.

Ramsay, J. O. y Silverman, B. W. (2002), *Análisis aplicado de datos funcionales: métodos y estudios de caso*, Springer.

Rosenbaum, D. (2004), «Cómo medir la contribución de los jugadores de la NBA a las victorias de sus equipos», *http://www.82games.com/comm30.htm*.

Sabin, R. P. (2021), «Estimación del valor de los jugadores en el fútbol americano mediante modelos plus-minus», *Journal of Quantitative Analysis in Sports* **17**(4), 313–364.

Sill, J. (2010), «Improved NBA Adjusted+/- using regularization and out-of-sample testing», *en* «Actas de la Conferencia de Análisis Deportivo del MIT Sloan 2010».

Smola, A. J. y Kondor, R. (2003), «Kernels y regularización en grafos», *en* «Teoría del aprendizaje y máquinas de kernel: 16.ª Conferencia Anual sobre Teoría del Aprendizaje y 7.º Taller sobre Kernel, COLT/Kernel 2003, Washington, D.C., EE. UU., 24-27 de agosto de 2003. Actas», Springer, pp. 144–
158.

Upton, E. y Carvalho, L. (2024), «Modelación de la incidencia de delitos urbanos mediante regresión regularizada en redes», *The Annals of Applied Statistics* **18**(4), 3364–3382.

A Apéndice

En la especificación del modelo LAPM, tenemos

$$Y_v \mid \beta \overset{ind}{\sim} N(\beta_v, \sigma^2)$$
$$\beta \sim N(0, \lambda^{-1} L_w^{-1}).$$

Para evaluar la incertidumbre en nuestro proceso de modelado, una opción es fijar un valor para σ^2, es decir, considerarlo como un valor conocido. Como alternativa, podríamos ampliar la definición del modelo permitiendo que σ^2sea una variable aleatoria con una distribución a priori de chi-cuadrado invertido y escalado:

$$Y_v \mid \beta \overset{ind}{\sim} N(\beta_v, \sigma^2)$$
$$\beta \sim N(0, \lambda^{-1} L_w^{-1})$$
$$\frac{1}{\sigma^2} \sim \Gamma(\nu/2, \frac{\nu\delta^2}{2}).$$

Para el análisis presentado en el artículo, optamos por utilizar una distribución a priori no informativa para σ^2, estableciendo $v = \tau^2 = 0$. Utilizamos el algoritmo de Langevin ajustado de Metropolis (Girolami y Calderhead, 2011) para obtener muestras de las distribuciones a posteriori. Las distribuciones a posteriori que se muestran a lo largo del manuscrito se basan en 1000 muestras, tras descartar el 10 % correspondiente a un período de burn-in y reducir el tamaño de la muestra cada 5 muestras.

Cabe señalar que, si bien el centro y la dispersión de las distribuciones a posteriori (y, por lo tanto, los valores ajustados) son sensibles a la especificación de la distribución a priori, las *clasificaciones* resultantes de las alineaciones generalizadas no lo son. Además, aunque fijamos los parámetros de la hiperdistribución a priori para que sean los mismos para todos los equipos, podría valer la pena investigar los parámetros a nivel de equipo si ese es el principal interés del lector.

B Apéndice

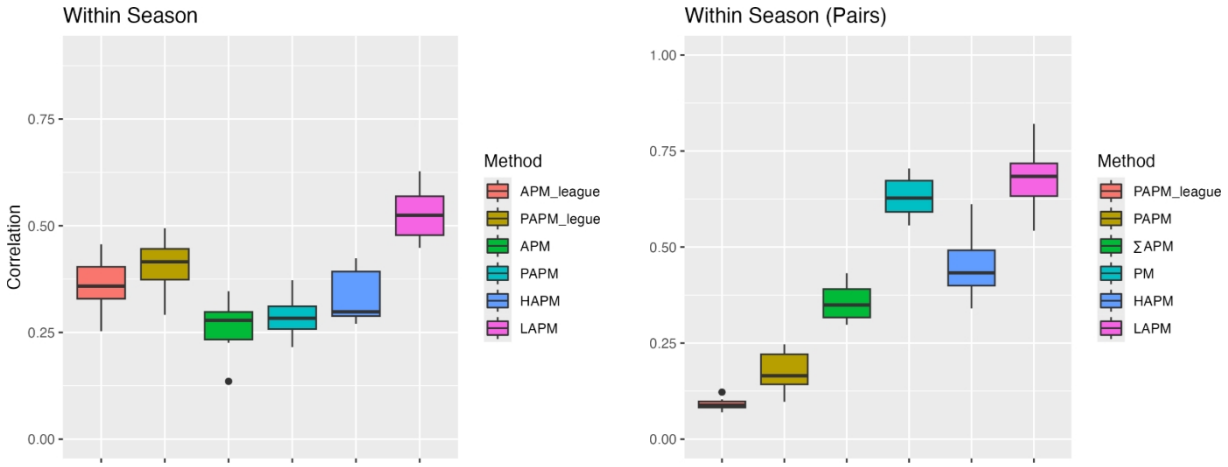

Figura A1: Correlación de rangos de Spearman para cada método dentro de un mismo año y con respecto a sí mismo, para individuos (izquierda) y pares (derecha) a lo largo de los años 2012-2022.

C Apéndice

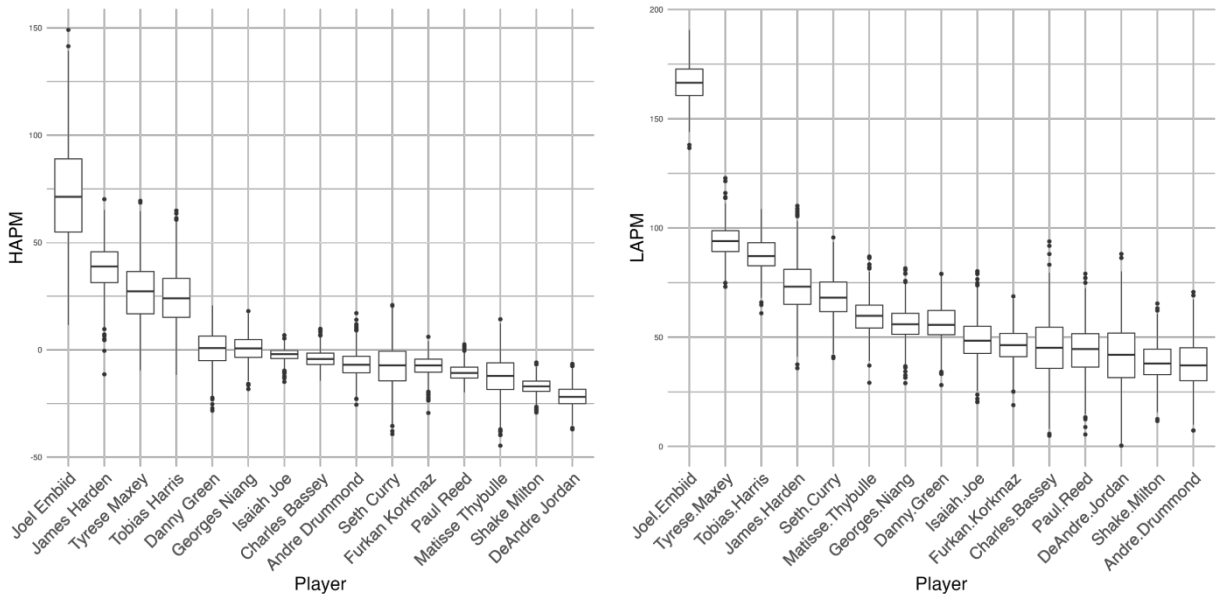

Figura A2: HAPM (izquierda) y LAPM (derecha) para los jugadores de los Sixers en 2021-22. Los diagramas de caja representan la distribución de los valores de HAPM y LAPM obtenidos mediante bootstrap y MCMC, respectivamente.

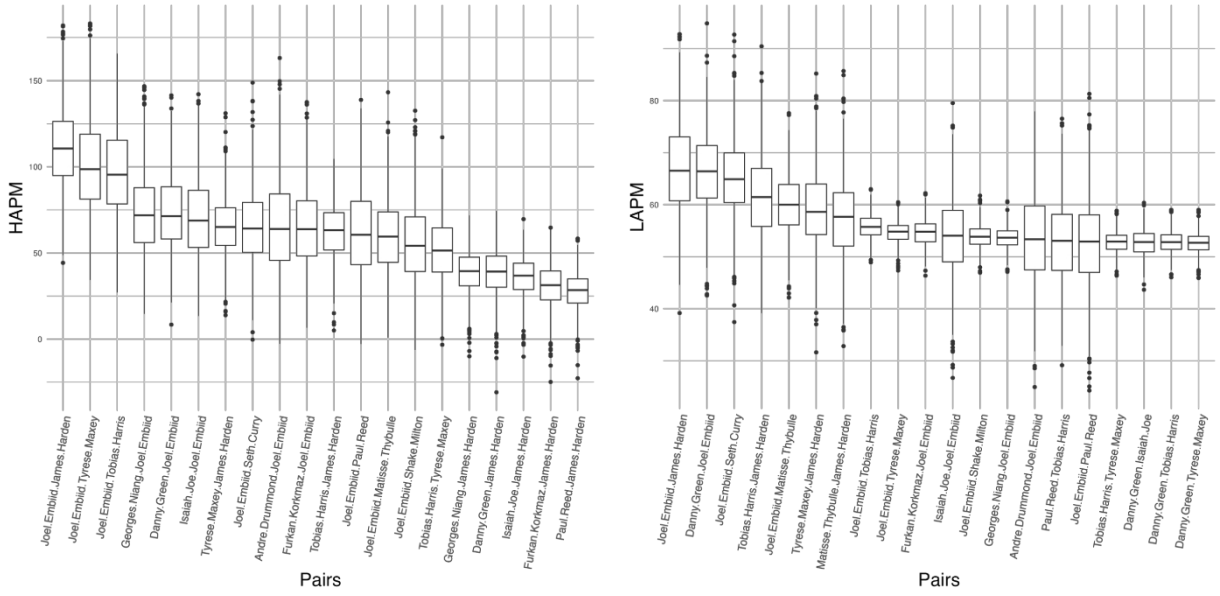

Figura A3: HAPM (izquierda) y LAPM (derecha) para las mejores parejas de los Sixers en 2021-22. Los diagramas de caja representan la distribución de los valores de HAPM y LAPM obtenidos mediante bootstrap y MCMC, respectivamente.

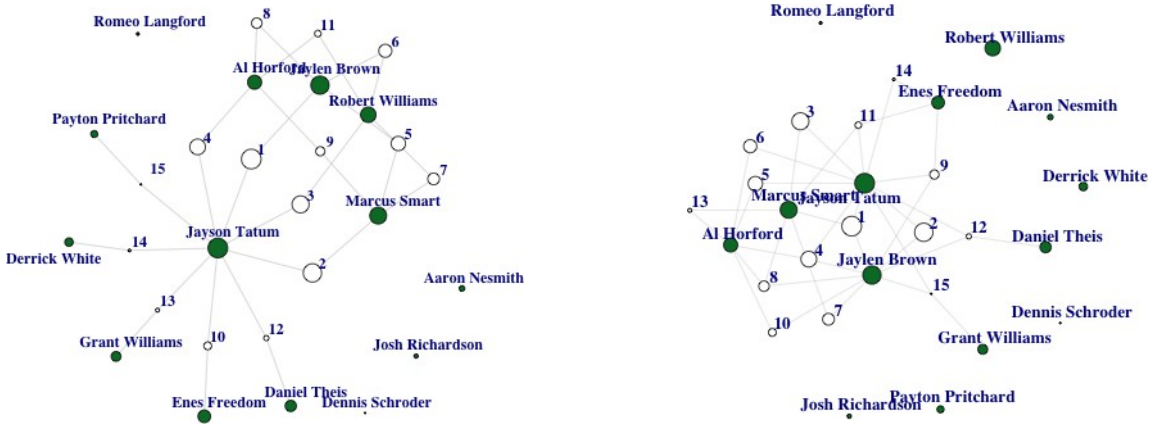

Figura A4: Visualización en gráfico de líneas de las clasificaciones de HAPM por jugador/pareja (izquierda) y jugador/trío (derecha) para los BOS en la temporada 2021-22. El tamaño de los nodos corresponde a la clasificación dentro de los individuos, parejas o tríos. Los nodos verdes representan a los jugadores, y los nodos blancos, etiquetados con el rango, representan a la pareja o al trío.